

Universidad Nacional de Asunción Facultad Politécnica

Diplomado Big Data y Business Analytics

Tarea Data Streaming

Unidad V: Procesamiento de Flujo de Datos Masivos

Profesor: Rodrigo Manuel Parra Zacarías

Alumna: Claudia Noemí Palacios Romero - CI: 3.710.469





Identificación

Unidad V: Procesamiento de Flujo de Datos Masivos

Curso: Big Data y Business Analytics

Objetivo

El objetivo de esta tarea es fijar los contenidos desarrollados durante el módulo de Data Streaming, incluyendo la aplicación de herramientas como Redpanda y KSQLDB para la solución de un problema.

Instrucciones

La tarea consiste en construir un servicio que consuma la API en tiempo real de Finnhub: https://finnhub.io/docs/api/websocket-trades y consuma actualizaciones para los siguientes símbolos:

- AAPL
- AMZN
- BINANCE:BTCUSDT

De modo a procesar las actualizaciones, deben seguirse los siguientes pasos:

- 1. Instalar un cluster Redpanda de manera local utilizando un archivo docker-compose.yml
- 2. Implementar un producer utilizando kafka-python, de acuerdo a la documentación de Redpanda y similar al ejemplo desarrollado en clase, para suscribirse a los eventos de la API.
- 3. Instalar KSQLDB modificando el archivo docker-compose.yml, de acuerdo a la documentación de Redpanda.
- 4. Ejecutar ksqldb-cli, definir los streams y tablas necesarios para responder a las siguientes preguntas:
 - 1. ¿Cuál fue el promedio ponderado de precio de una unidad por cada uno de los símbolos procesados? (e.j. AAPL)
 - 2. ¿Cuántas transacciones se procesaron por símbolo?
 - 3. ¿Cuál fue el máximo precio registrado por símbolo?
 - 4. ¿Cuál fue el mínimo precio registrado por símbolo?

Presentación

El proyecto debe desarrollarse en los grupos previamente formados. El entregable debe incluir:

- •Enlace a repositorio público de Github incluyendo:
 - -docker-compose.yml
 - -código fuente del producer
 - -archivos .sql con las 4 consultas utilizadas para responder las preguntas de la sección anterior
- •Una grabación de pantalla mostrando el sistema en funcionamiento y explicando brevemente los pasos que se siguieron para su implementación.

Fecha límite de entrega: 21-08-2023 23:59





Archivo: docker-compose.yml contruido en función a los requerimientos planteados

```
version: "3.7"
name: redpanda-cpalacios
networks:
 redpanda_network-1:
    driver: bridge
volumes:
 redpanda-1: null
services:
  redpanda-1:
    command:
      - redpanda
      - start
      - --kafka-addr internal://0.0.0.0:9092,external://0.0.0.0:19092
      - --advertise-kafka-addr internal://redpanda-1:9092,external://localhost:19092
      - --pandaproxy-addr internal://0.0.0.0:8082,external://0.0.0.0:18082
- --advertise-pandaproxy-addr internal://redpanda-1:8082,external://localhost:18082
- --schema-registry-addr internal://0.0.0.0:8081,external://0.0.0.0:18081
      - --rpc-addr redpanda-1:33145
      - --advertise-rpc-addr redpanda-1:33145
      - --smp 1
      - --memory 1G
      - --mode dev-container
      - --default-log-level=debug
    image: docker.redpanda.com/redpandadata/redpanda:v23.2.6
    container_name: redpanda-1
    volumes:
      - redpanda-1:/var/lib/redpanda/data
    networks:
      - redpanda_network-1
    ports:
      - 18081:18081
      - 18082:18082
      - 19092:19092
      - 19644:9644
  console-1:
    container_name: redpanda-console-1
    image: docker.redpanda.com/redpandadata/console:v2.3.1
    entrypoint: /bin/sh
    command: -c 'echo "$$CONSOLE_CONFIG_FILE" > /tmp/config.yml; /app/console'
    environment:
      CONFIG FILEPATH: /tmp/config.yml
      CONSOLE_CONFIG_FILE: |
        kafka:
          brokers: ["redpanda-1:9092"]
           schemaRegistry:
             enabled: true
             urls: ["http://redpanda-1:8081"]
        redpanda:
           adminApi:
            enabled: true
             urls: ["http://redpanda-1:9644"]
    depends on:
       redpanda-1
    networks:
      - redpanda_network-1
    ports:
      - 8080:8080
  ksqldb-server-1:
    image: confluentinc/ksqldb-server:0.25.1
    hostname: ksqldb-server-1
    container name: ksgldb-server-1
    depends on:
       - redpanda-1
    networks:
      - redpanda_network-1
    ports:
- "8088:8088"
    environment:
      KSQL LISTENERS: "http://0.0.0.0:8088"
      KSQL BOOTSTRAP_SERVERS: "redpanda-1:9092"
KSQL_KSQL_SCHEMA_REGISTRY_URL: "http://schema-registry:8081"
```

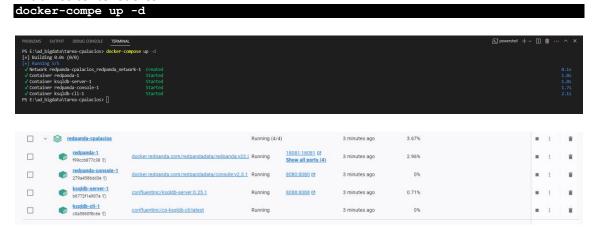




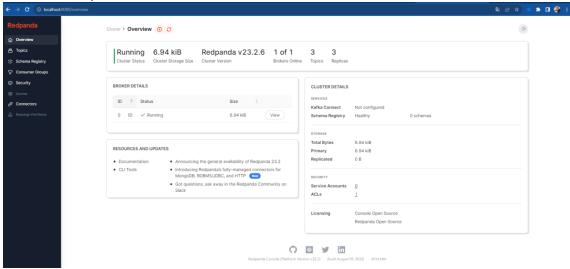
```
KSQL_KSQL_LOGGING_PROCESSING_STREAM_AUTO_CREATE: "true"
KSQL_KSQL_LOGGING_PROCESSING_TOPIC_AUTO_CREATE: "true"

ksqldb-cli-1:
    image: confluentinc/cp-ksqldb-cli:latest
    container_name: ksqldb-cli-1
    depends_on:
        - redpanda-1
        - ksqldb-server-1
networks:
        - redpanda_network-1
entrypoint: /bin/sh
tty: true
```

Iniciar los contenedores:



Prueba de Redpanda Console:



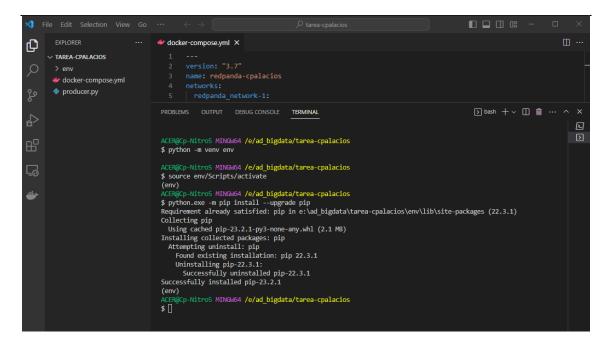
Preparación de entorno Python

En Windows:

```
python -m venv env
source env/Scripts/activate
python.exe -m pip install --upgrade pip
```







Instalación de requerimientos:

pip install kafka-python

```
(env)

ACER@Cp-Nitro5 MINGW64 /e/ad_bigdata/tarea-cpalacios

$ pip install kafka-python

Collecting kafka-python

Using cached kafka_python-2.0.2-py2.py3-none-any.whl (246 kB)

Installing collected packages: kafka-python

Successfully installed kafka-python-2.0.2

(env)
```

pip install websocket-client

Evaluación de estado:

docker exec -it redpanda-1 rpk cluster info --brokers=127.0.0.1:19092





```
(env)

ACER@Cp-Nitro5 MINGW64 /e/ad_bigdata/tarea-cpalacios
$ docker exec -it redpanda-1 rpk cluster info --brokers=127.0.0.1:19092
CLUSTER
=======
redpanda.46dbbe38-62af-434c-a56a-28b4b91d0e90

BROKERS
======
ID HOST PORT
0* localhost 19092

TOPICS
=====
NAME PARTITIONS REPLICAS
_confluent-ksql-default_command_topic 1 1
_schemas 1 1
_default_ksql_processing_log 1 1

(env)
ACER@Cp-Nitro5 MINGW64 /e/ad_bigdata/tarea-cpalacios
$ | |
```

Estado del Cluster

docker exec -it redpanda-1 rpk cluster info

```
(env)

ACER@Cp-Nitro5 MINGW64 /e/ad_bigdata/tarea-cpalacios

$ docker exec -it redpanda-1 rpk cluster info

CLUSTER

======
redpanda.46dbbe38-62af-434c-a56a-28b4b91d0e90

BROKERS
======
ID HOST PORT
0* redpanda-1 9092

TOPICS
=====
NAME PARTITIONS REPLICAS
_confluent-ksql-default__command_topic 1 1
_schemas 1 1
default_ksql_processing_log 1 1

(env)

ACER@Cp-Nitro5 MINGW64 /e/ad_bigdata/tarea-cpalacios

$ □
```

Creación de un topic llamado "reg-updates":

docker exec -it redpanda-1 rpk topic create reg-updates

```
PROBLEMS OUTPUT DEBUG CONSOLE TERMINAL

(env)

ACER@Cp-Nitro5 MINGM64 /e/ad_bigdata/tarea-cpalacios

$ docker exec -it redpanda-1 rpk topic create reg-updates

TOPIC STATUS

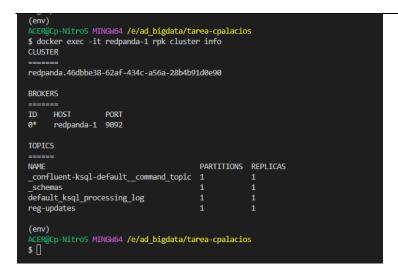
reg-updates OK
(env)

ACER@Cp-Nitro5 MINGW64 /e/ad_bigdata/tarea-cpalacios

$ []
```









Implementación de producer utilizando kafka-python, de acuerdo a la documentación de Redpanda para suscribirse a los eventos de la API.

Archivo: producer.py

```
import json
import traceback
from datetime import datetime
import websocket
from kafka import KafkaProducer
from kafka.errors import KafkaError
producer = KafkaProducer(
   bootstrap_servers="localhost:19092",
value_serializer=lambda m: json.dumps(m).encode("ascii"),
topic = "reg-updates"
# Redpanda handlers
def on success (metadata):
   print(f"Mensaje producido para topic '{metadata.topic}' con offset {metadata.offset}")
def on_error(e):
    print(f"Error al enviar mensaje: {e}")
# WS handlers
def on_ws_message(ws, message):
    data = json.loads(message)["data"]
    records = [
```

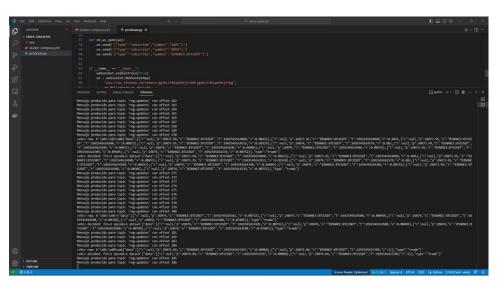




```
for d in data
     for record in records:
          future = producer.send(topic, value=record)
         future.add_callback(on_success)
future.add_errback(on_error)
         producer.flush()
def on_ws_error(ws, error):
    print(error)
def on_ws_close(ws, close_status_code, close_msg):
    producer.close()
    print("### Cerrado ###")
def on ws open(ws):
    ws.send('{"type":"subscribe","symbol":"AAPL")')
ws.send('{"type":"subscribe","symbol":"AMZN"}')
ws.send('{"type":"subscribe","symbol":"BINANCE:BTCUSDT"}')
ws = websocket.WebSocketApp(
         "wss://ws.finnhub.io?token=cjg2bc1r01qohhhj7s60cjg2bc1r01qohhhj7s6g",
         on_message=on_ws_message,
         on_error=on_ws_error,
on_close=on_ws_close,
     ws.on_open = on_ws_open
     ws.run_forever()
```

Correr el producer:

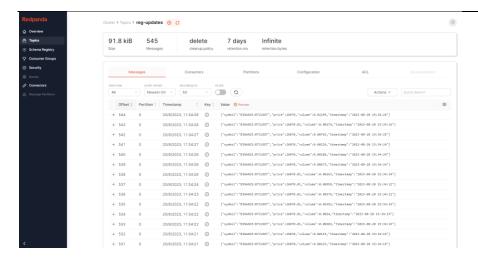
python producer.py



Esto va a empezar a cargar el topic reg-updates







Nota: en el experimento, solo se vieron llegar de BINANCE:BTCUSDT

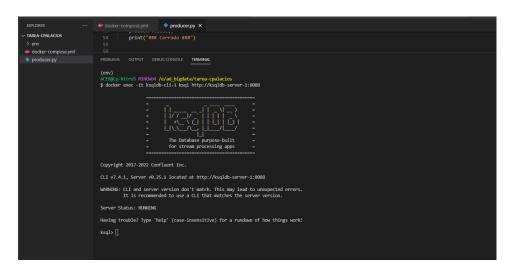
El consumer

Ejecutar ksqldb-cli, definir los streams y tablas necesarias para responder a las siguientes preguntas:

- 1. ¿Cuál fue el promedio ponderado de precio de una unidad por cada uno de los símbolos procesados? (e.j. AAPL)
- 2. ¿Cuántas transacciones se procesaron por símbolo?
- 3. ¿Cuál fue el máximo precio registrado por símbolo?
- 4. ¿Cuál fue el mínimo precio registrado por símbolo?

Iniciar ksqlDB y acceder a su interfaz

docker exec -it ksqldb-cli-1 ksql http://ksqldb-server-1:8088



Revisamos si ya tenemos topics creados:

ksql> SHOW TOPICS;





Creación del stream en ksqlDB

Este comando crea no solo un **STREAM**, sino también un topic de Redpanda, si aún no existe. Si el tema ya existe, el comando define la secuencia, que luego se puede seleccionar con sintaxis SQL.

Para este caso ya creemos el topic

```
CREATE STREAM registros (symbol VARCHAR, price DOUBLE, volume DOUBLE, timestamp STRING) WITH (kafka_topic='reg-updates', value_format='json', partitions=1);
```

```
ksql> SET 'auto.offset.reset' = 'earliest';
```

```
ksql> SET 'auto.offset.reset' = 'earliest';
Successfully changed local property 'auto.offset.reset' to 'earliest'. Use the UNSET command to revert your change.
ksql> [
```

ksql> SELECT * FROM registros;





PROBLEMS OUTPUT	DEBUG CONSOLE T	ERMINAL		
BINANCE:BTCUSDT		26097.41	0.00044	2023-08-20 15:59:29
BINANCE:BTCUSDT		26097.42	0.0045	2023-08-20 15:59:29
BINANCE:BTCUSDT		26097.41	0.00709	2023-08-20 15:59:30
BINANCE:BTCUSDT		26097.41	0.00031	2023-08-20 15:59:30
BINANCE:BTCUSDT		26097.42	0.00181	2023-08-20 15:59:30
BINANCE:BTCUSDT		26097.42	0.00383	2023-08-20 15:59:30
BINANCE:BTCUSDT		26097.42	0.0054	2023-08-20 15:59:30
BINANCE:BTCUSDT		26097.42	0.00646	2023-08-20 15:59:30
BINANCE:BTCUSDT		26097.42	0.0063	2023-08-20 15:59:30
BINANCE:BTCUSDT		26097.42	0.00483	2023-08-20 15:59:30
BINANCE:BTCUSDT		26097.47	0.00179	2023-08-20 15:59:30
BINANCE:BTCUSDT		26097.48	0.00229	2023-08-20 15:59:31
BINANCE:BTCUSDT		26097.47	0.00306	2023-08-20 15:59:31
BINANCE:BTCUSDT		26097.47	0.00456	2023-08-20 15:59:31
BINANCE:BTCUSDT		26097.47	0.00306	2023-08-20 15:59:31
BINANCE:BTCUSDT		26097.47	0.00077	2023-08-20 15:59:31
BINANCE:BTCUSDT		26097.47	0.00078	2023-08-20 15:59:31
BINANCE:BTCUSDT		26097.47	0.00117	2023-08-20 15:59:31
BINANCE:BTCUSDT		26097.47	0.00459	2023-08-20 15:59:31
BINANCE:BTCUSDT		26097.47	0.00306	2023-08-20 15:59:31
BINANCE:BTCUSDT		26097.47	0.00126	2023-08-20 15:59:31
BINANCE:BTCUSDT		26097.47	0.00337	2023-08-20 15:59:31
BINANCE:BTCUSDT		26097.47	0.00306	2023-08-20 15:59:31
BINANCE:BTCUSDT		26097.47	0.00114	2023-08-20 15:59:31
BINANCE:BTCUSDT		26097.47	0.00076	2023-08-20 15:59:31
BINANCE:BTCUSDT		26097.47	0.00076	2023-08-20 15:59:31
BINANCE:BTCUSDT		26097.47	0.00084	2023-08-20 15:59:31
BINANCE:BTCUSDT		26097.47	0.00604	2023-08-20 15:59:31
BINANCE:BTCUSDT		26097.47	0.00306	2023-08-20 15:59:31
BINANCE:BTCUSDT		26097.47	0.00078	2023-08-20 15:59:31
BINANCE:BTCUSDT		26097.47	0.00381	2023-08-20 15:59:31
BINANCE:BTCUSDT		26097.48	0.00408	2023-08-20 15:59:31
BINANCE:BTCUSDT		26097.48	0.00116	2023-08-20 15:59:31
BINANCE:BTCUSDT		26097.48	0.00575	2023-08-20 15:59:31
BINANCE:BTCUSDT		26097.76	0.00057	2023-08-20 15:59:31
BINANCE:BTCUSDT		26098.18	0.00595	2023-08-20 15:59:31
BINANCE:BTCUSDT		26098.26	0.0017	2023-08-20 15:59:31
BINANCE:BTCUSDT		26098.6	0.00078	2023-08-20 15:59:31
BINANCE:BTCUSDT		26098.77	0.00219	2023-08-20 15:59:31
BINANCE:BTCUSDT		26098.77	0.00086	2023-08-20 15:59:31
BINANCE:BTCUSDT		26098.78	0.01915	2023-08-20 15:59:31
BINANCE:BTCUSDT		26099.0	0.026	2023-08-20 15:59:31
BINANCE:BTCUSDT		26099.09	0.00039	2023-08-20 15:59:31

Creación de vistas materializadas

```
CREATE TABLE reg_record AS

SELECT symbol,

count(price) AS total_registros

FROM registros

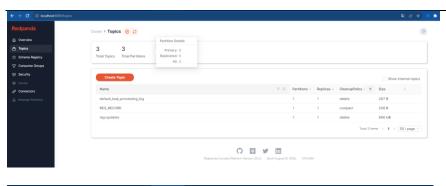
GROUP BY symbol

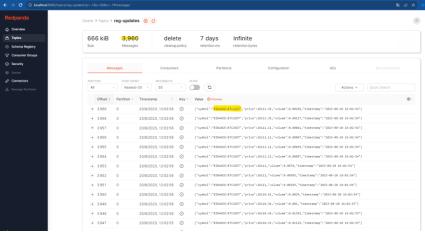
EMIT CHANGES;
```

```
PROBLEMS OUTPUT DEBUG CONSOLE TERMINAL
ksql> SHOW TOPICS;
Kafka Topic
                           | Partitions | Partition Replicas
default_ksql_processing_log | 1
reg-updates | 1
ksql> CREATE TABLE reg_record AS
> SELECT symbol,
       count(price) AS total_registros
   FROM registros
> GROUP BY symbol
> EMIT CHANGES;
Message
Created query with ID CTAS_REG_RECORD_5
ksql> SHOW TOPICS;
Kafka Topic
                           | Partitions | Partition Replicas
REG RECORD
default_ksql_processing_log | 1
                                          1
reg-updates
                             | 1
                                          1
ksql> [
```



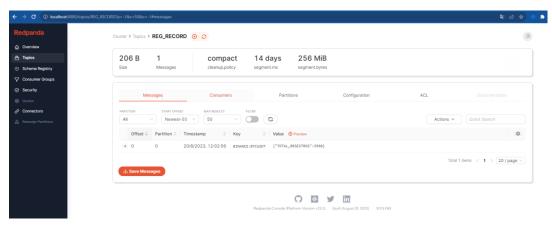






SELECT * FROM reg record;









¿Cuál fue el promedio ponderado de precio de una unidad por cada uno de los símbolos procesados? (e.j. AAPL)

Tabla:

```
CREATE TABLE reg_prom AS

SELECT symbol,

count(price) AS total_registros,
sum(price*volume) AS weighted_price,
sum(volume) AS total_volume,
sum(price*volume)/sum(volume) AS promedio
FROM registros
GROUP BY symbol
EMIT CHANGES;
```

```
ksql> SHOW TOPICS;

Kafka Topic | Partitions | Partition Replicas

REG_PROM | 1 | 1

REG_RECORD | 1 | 1

default_ksql_processing_log | 1 | 1

reg-updates | 1 | 1

ksql> [
```

General:

```
SELECT * FROM reg_prom;
```

ksql> SELECT * FROM reg_prom;				
SYMBOL	TOTAL_REGISTROS	WEIGHTED_PRICE	TOTAL_VOLUME	PROMEDIO
BINANCE:BTCUSDT Query terminated ksql> []	3960	 4891799.6748312855	156.85854000000032	26085.922220308803

Consulta por symbol:

```
SELECT * FROM reg_prom
WHERE symbol = 'BINANCE:BTCUSDT';
```

```
SELECT * FROM reg_prom
WHERE symbol = 'AAPL';
```





SELECT * FROM reg_prom
WHERE symbol = 'AMZN';

ksql> SELECT * FROM reg_prom >WHERE symbol = 'BINANCE:BTCUSDT';					
SYMBOL		WEIGHTED_PRICE	TOTAL_VOLUME	PROMEDIO	
		4091799.6740312055 	156.85854000000032	26085.922220308803	
SYMBOL	TOTAL_REGISTROS	WEIGHTED_PRICE	TOTAL_VOLUME	PROMEDIO	
Query terminated ksql> SELECT * FROM reg_prom >WHERE symbol = 'AMZN';					
SYMBOL	TOTAL_REGISTROS	WEIGHTED_PRICE	TOTAL_VOLUME	PROMEDIO	
Query terminated ksql> [•	*			

¿Cuántas transacciones se procesaron por símbolo?

Tabla:

```
CREATE TABLE reg_record AS

SELECT symbol,

count(price) AS total_registros

FROM registros

GROUP BY symbol

EMIT CHANGES;
```

General:

SELECT * FROM reg_record;

SYMBOL	TOTAL_REGISTROS
BINANCE:BTCUSDT Query terminated ksql> SELECT * FROM reg_record;	6150
SYMBOL	TOTAL_REGISTROS
BINANCE:BTCUSDT Query terminated ksql> SELECT * FROM reg_record;	6315
SYMBOL	TOTAL_REGISTROS
	6316

Consulta por symbol:

```
SELECT * FROM reg_record
WHERE symbol = 'BINANCE:BTCUSDT';
```

```
SELECT * FROM reg_record
WHERE symbol = 'AAPL';
```

```
SELECT * FROM reg_record
WHERE symbol = 'AMZN';
```





¿Cuál fue el máximo precio registrado por símbolo?

Tabla:

```
CREATE TABLE maxprice_record AS
SELECT symbol,
max(price) AS precio_maximo
FROM registros
GROUP BY symbol
EMIT CHANGES;
```

```
TERMINAL
ksql> CREATE TABLE maxprice_record AS
 SELECT symbol,
           max(price) AS precio_maximo
    FROM registros
    GROUP BY symbol
    EMIT CHANGES;
Message
Created query with ID CTAS_MAXPRICE_RECORD_11
ksql> SHOW TOPICS;
                             | Partitions | Partition Replicas
Kafka Topic
MAXPRICE RECORD
                                          | 1
REG PROM
REG_RECORD
                                          | 1
default_ksql_processing_log | 1
reg-updates | 1
                                          | 1
ksql> [
```

General:

```
SELECT * FROM maxprice_record;
```

Consulta por symbol:

```
SELECT * FROM maxprice_record
```





WHERE symbol = 'BINANCE:BTCUSDT';

```
SELECT * FROM maxprice_record
WHERE symbol = 'AAPL';
```

```
SELECT * FROM maxprice_record
WHERE symbol = 'AMZN';
```

```
| RECTO_MAXINO | PRECTO_MAXINO | PRECTO_MAXINO
```

¿Cuál fue el mínimo precio registrado por símbolo?

Tabla:

```
CREATE TABLE minprice_record AS
SELECT symbol,
min(price) AS precio_minimo
FROM registros
GROUP BY symbol
EMIT CHANGES;
```

```
PROBLEMS OUTPUT DEBUG CONSOLE TERMINAL
ksql> CREATE TABLE minprice_record AS
    SELECT symbol,
min(price) AS precio_minimo
    FROM registros
GROUP BY symbol
EMIT CHANGES;
 Message
Created query with ID CTAS_MINPRICE_RECORD_14
ksql> SHOW TOPICS;
                                 | Partitions | Partition Replicas
 Kafka Topic
 MAXPRICE RECORD
 MINPRICE_RECORD
                                                 | 1
| 1
| 1
| 1
| 1
 REG_PROM
 REG_RECORD
default_ksql_processing_log | 1
reg-updates | 1
ksql> [
```

General:

SELECT * FROM minprice_record;







Consulta por symbol:

SELECT * FROM minprice_record
WHERE symbol = 'BINANCE:BTCUSDT';

SELECT * FROM minprice_record
WHERE symbol = 'AAPL';

SELECT * FROM minprice_record
WHERE symbol = 'AMZN';

